



Model statystyczny

Estymacja punktowa

Estymatory
nieobciążone

Elementy statystyki

STA - Wykład 2

dr hab. Waldemar Wołyński
Wydział Matematyki i Informatyki
Uniwersytet im. Adama Mickiewicza



Model statystyczny

Model statystyczny

Estymacja punktowa

Estymatory
nieobciążone

Model: jedna próba

Jeżeli próbka $\mathbf{x} = (x_1, \dots, x_n)'$ jest **reprezentatywna**, to stanowi ona podstawę do wnioskowania o **populacji** z której pochodzi. Wnioskowanie takie wymaga zbudowania modelu "zachowania się" zmiennej X w populacji. Budowa modelu polega na przyjęciu założenia o rozkładzie (teoretycznym) zmiennej X w populacji oraz traktowaniu obserwacji jako wartości tej zmiennej.

Dokładniej: budując model statystyczny traktujemy wektor obserwacji (próbę) $\mathbf{x} = (x_1, \dots, x_n)'$ jak realizację wektora losowego (próby) $\mathbf{X} = (X_1, \dots, X_n)'$ z nieznanego (lub jedynie częściowo nieznanego) rozkładu.

Statystyka, to każda (mierzalna) funkcja próby. Zatem w modelu, statystyka jest wielkością losową.



Model: jedna próba prosta



Modelujemy wyniki doświadczenia w którym dokonujemy n -**niezależnych** obserwacji badanej cechy X na losowo wybranych z populacji (jednorodnej ze względu na badaną cechę) jednostkach eksperymentalnych.

Przykład 1. W celu określenia czasu bezawaryjnej pracy urządzeń po wykonaniu kapitalnego remontu, wybrano 50 urządzeń i obserwowano czas ich bezawaryjnej pracy. Wyniki (w h.) są następujące: 629, 325, 215, ... ,612, 841, 492. Budując model statystyczny tego eksperymentu zakładamy, że (w populacji) czas bezawaryjnej pracy urządzenia (cecha X) ma rozkład wykładniczy z nieznanym parametrem λ .

Model ten ma jeden parametr: λ .



Przykład 2. Przeprowadzono 50 niezależnych eksperymentów polegających na hamowaniu badanego typu samochodu wyposażonego w nowy typ układu hamulcowego (na suchym asfalcie, przy prędkości 40 km/h, itd.). Notowano długość drogi hamowania z dokładnością do jednego centymetra. Otrzymane wyniki to: 18.66, 17.81, 18.96, ... , 17.62, 18.61, 17.99. Budując model statystyczny tego eksperymentu zakładamy, że (w populacji) długość drogi hamowania (cecha X) ma rozkład normalny z nieznanymi parametrami μ i σ^2

Uwaga! Model ten często zapisujemy w następującej postaci:

$$X_i = \mu + \varepsilon_i, \quad i = 1, \dots, n,$$

gdzie

X_i – i -ta obserwacja badanej cechy X ,

μ – wartość oczekiwana (średnia, "prawdziwa" wartość)
badanej cechy X ,

ε_i – błędy (niezależne zmienne losowe o jednakowym
rozkładzie $N(0, \sigma^2)$).

Model ten ma dwa parametry: μ i σ^2 .



Estymacja punktowa

Metoda największej wiarygodności



Niech $\mathbf{X} = (X_1, X_2, \dots, X_n)'$ będzie próbą z populacji o rozkładzie P_θ , gdzie $\theta \in \Theta \subset \mathbf{R}^d$.

Ponadto, niech rozkłady P_θ opisane będą za pomocą funkcji prawdopodobieństwa (gęstości) p_θ .

Definicja

Funkcję L określoną wzorem

$$L(\theta; \mathbf{x}) = p_\theta(\mathbf{x})$$

*nazywamy **funkcją wiarygodności**.*

Uwaga! Funkcją wiarygodności nazywamy czasem funkcję $\ln p_\theta(\mathbf{x})$.



Definicja

Estymatorem największej wiarygodności (ENW) parametru θ nazywamy statystykę $\hat{\theta}(\mathbf{X})$, której wartości $\hat{\theta}(\mathbf{x})$ spełniają warunek:

$$\forall \mathbf{x} \in \mathcal{X} : L(\hat{\theta}(\mathbf{x}); \mathbf{x}) = \sup_{\theta \in \Theta} L(\theta; \mathbf{x}).$$

Uwagi! 1) Dla danego parametru θ , ENW może nie istnieć lub może być wyznaczony niejednoznacznie.
2) Zazwyczaj, podczas wyznaczanie ENW, wygodniej jest operować funkcją $\ln L$ niż funkcją L .

Estymacja parametru λ w modelu wykładniczym

Do estymacji parametru λ (przykład 1) możemy użyć metody **największej wiarogodności**.

Fakt

Estymatorem największej wiarogodności (ENW) parametru λ , w modelu jednej próby prostej z rozkładu wykładniczego, jest statystyka

$$\hat{\lambda} = \frac{1}{\bar{X}}.$$



Estymacja parametru μ w modelu normalnym



Do estymacji parametru μ (przykład 2) możemy użyć metody **najmniejszych kwadratów**, polegającej na minimalizacji sumy kwadratów błędów, tzn.

$$S(\mu) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (x_i - \mu)^2.$$

Fakt

Estymatorem najmniejszych kwadratów (ENK) parametru μ , w modelu jednej próby prostej z rozkładu normalnego, jest statystyka

$$\hat{\mu} = \bar{X}.$$

Uwaga! Zwróćmy uwagę, że normalność rozkładu obserwacji (błędów) nie jest konieczna. Wystarczy jedynie założenie niezależności (a nawet nieskorelowania) błędów.



Estymatory nieobciążone



Niech $\theta \in \Theta$ oznacza parametr modelu statystycznego.

Definicja

*Statystykę $\hat{\theta}$ nazywamy **estymatorem nieobciążonym** parametru θ , gdy dla każdego $\theta \in \Theta$:*

$$E(\hat{\theta}) = \theta.$$

Uwaga! Klasa estymatorów nieobciążonych danego parametru może być pusta. Zazwyczaj jednak, dla danego parametru istnieje wiele różnych estymatorów nieobciążonych. Najlepszym z nich jest ten, który ma minimalną wariancję - estymator nieobciążony o minimalnej wariancji (ENMW).



Fakt

W modelu jednej próby prostej z rozkładu wykładniczego, ENW parametru λ postaci

$$\hat{\lambda} = \frac{1}{\bar{X}}$$

jest obciążonym estymatorem tego parametru.

Estymator nieobciążony (o minimalnej wariancji) parametru λ ma postać:

$$\hat{\lambda} = \frac{n-1}{n\bar{X}}$$



Fakt

W modelu jednej próby prostej z rozkładu normalnego, ENK parametru μ postaci

$$\hat{\mu} = \bar{X}$$

jest nieobciążonym (o minimalnej wariancji) estymatorem tego parametru.

Ponadto, statystyka

$$\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

jest nieobciążonym (o minimalnej wariancji) estymatorem parametru σ^2 .



Definicja

Niech X_1, X_2, \dots, X_n będą niezależnymi zmiennymi losowymi o jednakowym rozkładzie $N(0, 1)$.

Mówimy, że zmienna losowa

$$X_1^2 + X_2^2 + \dots + X_n^2$$

ma rozkład **chi-kwadrat** z n stopniami swobody (ozn. $\chi^2(n)$).

Fakt

$$f(x) = \frac{1}{2^{n/2}\Gamma(n/2)} x^{(n/2)-1} e^{-(x/2)}, \quad x > 0.$$



Twierdzenie

W modelu jednej próby prostej z rozkładu normalnego estymatory

$$\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k \quad i \quad S^2 = \frac{1}{n-1} \sum_{k=1}^n (X_k - \bar{X})^2$$


są niezależnymi zmiennymi losowymi oraz

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad i \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

Trochę historii ...



Sir Ronald A. Fisher
(1890 - 1962)



Fisher w wieku 22 lat